Cenário e metodologia

Coleta de PRs e definição do cenário de pesquisa

30 PRs com revisão Copilot e 30 sem revisão automatizada identificada. Projeto: microsoft/vscode. Recorte: setembro de 2025. Coleta: 02/11/2026.

Tema e contexto

Análise comparativa do tempo de integração de Pull Requests com e sem revisão automatizada de código em um projeto de código aberto. O tempo até o merge descreve a demora entre a proposta de uma alteração e sua integração e é relevante para o fluxo de desenvolvimento de software.

Pergunta e objetivo

Existe diferença no tempo até o merge entre PRs com revisão automatizada de código identificada antes da integração e PRs sem revisão automatizada identificada no histórico público?

O objetivo é descrever essa associação e fornecer dados reais rastreáveis para calibrar as futuras simulações do LAB04, par P1: t de Welch versus Mann-Whitney. Esta etapa não calcula p-valores, não executa simulações e não apresenta uma recomendação empírica sobre qual teste é superior.

Grupos e variável

- Grupo A: PR de conta pessoal, integrado, com revisão formal do aplicativo copilot-pull-request-reviewer antes do merge. Neste estudo, a revisão automatizada é operacionalizada especificamente pelo GitHub Copilot. Outros aplicativos não são agrupados silenciosamente com ele.
- Grupo B: PR elegível sem revisão automatizada de código identificada no histórico público consultado, por API ou página sem paginação pendente. A presença de bot de CI, cobertura, cópia de PR ou atualização de dependências não define o grupo A.
- Casos com bot ou conteúdo ambíguo são excluídos e registrados. Um resumo descritivo ou aviso de revisão pulada, sozinho, não comprova revisão efetiva.
- Variável resposta: tempo_merge_h = (merged_at - created_at).total_seconds() / 3600, em horas corridas, com datas em UTC. Não usar closed_at como substituto de merged_at.

Fonte, recorte e seleção

Fonte primária: microsoft/vscode, projeto público do editor Visual Studio Code. Há histórico público de integração, revisão humana e revisão pelo aplicativo GitHub Copilot. O mesmo projeto fornece ambos os grupos, evitando confundir completamente presença de bot com origem do repositório.

O recorte fixado no arquivo coleta_config.json contém PRs criados entre 01/09/2025 às 00:00:00 UTC (inclusive) e 01/10/2025 às 00:00:00 UTC (exclusive), com merge anterior a esse limite final. A coleta é executada em 02/11/2026. PRs abertos e PRs fechados sem merge não integram a população elegível.

A moldura de candidatos é a união das primeiras 100 respostas de cada uma de duas buscas REST, ordenadas por criação: com interação do revisor Copilot e sem essa interação. A busca apenas localiza candidatos; a classificação final depende da evidência de revisão e das datas. Essa moldura limitada de 200 candidatos é uma amostra de conveniência por estratos do índice de busca, e não um censo do mês. Na união deduplicada, percorre-se a ordem crescente de criação, com desempate por número, até selecionar 30 elegíveis por grupo. Após preencher B, os demais candidatos do estrato sem Copilot deixam de ser examinados. Como A exige Copilot, esse estrato não fornece integrantes de A. Os tempos não são usados para ordenar a seleção ou remover observações extremas.

Os tamanhos efetivos, as exclusões e a data de extração estão em data/resumo_coleta.json e docs/registro_coleta.md.

Hipóteses e interpretação futura

Os testes serão bicaudais, com nível de significância planejado de 5%, porque a pergunta admite aumento ou redução do tempo de merge.

t de Welch: H0: a média populacional do tempo de merge no grupo A é igual à do grupo B. H1: essas médias diferem. O teste compara médias de amostras independentes e não exige variâncias iguais.

Mann-Whitney: H0 clássica: as distribuições populacionais dos tempos de merge são iguais. A alternativa bicaudal procura diferenças na posição relativa das observações pelos postos. O teste não é um detector universal de qualquer diferença de forma; distribuições distintas podem produzir a mesma probabilidade de superioridade. Sua leitura como comparação de medianas exige condições adicionais, como formas semelhantes e diferença de localização.

Os dois testes respondem a aspectos diferentes da pergunta ampla. Igualdade de médias não implica igualdade de distribuições. Na etapa de simulação será necessário explicitar o modelo que permite comparar o controle de erro tipo I sob um nulo comum.

Expectativa anterior à simulação

Tempos de merge podem apresentar assimetria à direita e valores extremos. Espera-se que Mann-Whitney seja menos sensível à magnitude de extremos e possa apresentar vantagens em alguns desses cenários. Welch permanece relevante quando a pergunta substantiva é sobre médias. Essa expectativa é qualitativa: esta etapa não demonstra maior poder ou melhor controle de erro de nenhum teste.

Limitações

A coleta é observacional e não demonstra que bots causam mudanças no tempo de merge. Porte e complexidade do PR, autor, disponibilidade dos revisores, caminhos alterados, tipo de mudança e práticas de manutenção podem confundir a associação. A seleção por quotas não é aleatória: A concentra criações de 05 a 17/09 e B de 01 a 02/09, um desequilíbrio temporal importante.

Selecionar apenas PRs já integrados até uma data fixa favorece mudanças que terminam mais rapidamente e exclui PRs demorados ainda abertos. A separação entre PRs com e sem Copilot pode refletir a adoção da ferramenta durante o mês; diferenças temporais devem ser examinadas antes de qualquer interpretação. PRs do mesmo autor ou revisados pela mesma equipe podem ser dependentes. A categoria User na API e a ausência de indicadores de automação são critérios operacionais de autoria pessoal, sem prova de que todo o trabalho foi feito por uma pessoa sem ferramentas de IA.

O grupo B significa ausência de revisão automatizada identificada no histórico público consultado. Revisões privadas, eventos removidos, edições e ferramentas que não deixam comentários podem não ser observados. Conteúdo de comentários editáveis é o disponível na data de coleta, e sua presença inicial não prova que toda edição já existia antes do merge. Os resultados não devem ser generalizados para outros projetos ou para todos os tipos de revisão.

Próxima etapa do grupo

Revisar manualmente uma amostra dos links de ambos os grupos. Depois, usar os dados reais para avaliar a forma da distribuição e definir os parâmetros do gerador. A simulação inicial, a aplicação dos testes e os gráficos G1 e G2 pertencem às demais atividades da Sprint 01.

Referências

Metadados e listagem de PRs na API REST do GitHub
Eventos completos da linha do tempo
Revisões de PRs
Revisão de código pelo GitHub Copilot
Mann-Whitney na documentação do SciPy